UNIVERSIDAD DE VALLADOLID

GRADO EN INGENIERÍA BIOMÉDICA

TÉCNICAS COMPUTACIONALES EN BIOMEDICINA

Práctica 1. Limpieza de datos multidimensionales. *Data curation*.

CURSO 2024/2025

ÍNDICE

1. Objetivos y metodología _____ **2**

2. Temporización _____ **2**

3. Descripción general del problema bajo estudio _____ **4**

4. Inspección de la base de datos. Consistencia de los datos: *missing values* y *outliers* _____ **4**

4.1. SESIÓN 1. Inspección de la base de datos. Valores perdidos (*missing values*) _ 4

4.2. SESIÓN 2. Inspección de la base de datos. Datos atípicos (*outliers*) _____ 6

5. EVALUACIÓN _____ **7**

1. OBJETIVOS Y METODOLOGÍA

En esta primera práctica se va a abordar el procesado de datos multidimensionales implementando la etapa que comúnmente desarrollaría en primer lugar cualquier ingeniero/científico de datos: el análisis descriptivo de los datos para la búsqueda y tratamiento de inconsistencias y datos perdidos. Para ello, se utilizará una base de datos con información procedente de la historia clínica electrónica y de la caracterización de una señal biomédica en el contexto de una patología respiratoria. Las variables contenidas en esta base de datos, una vez inspeccionadas y preprocesadas (limpieza de datos o *data curation*) se emplearán en las prácticas siguientes para diseñar y evaluar modelos predictivos. Los objetivos de la práctica consistirán en:

(i) Familiarizarse con el trabajo con datos clínicos reales.

(ii) Conocer e identificar los principales problemas relacionados con la inconsistencia de los datos y algunas de las soluciones disponibles para detectarlos y corregirlos.

Cada alumno realizará la práctica individualmente. Se propone un desarrollo guiado y supervisado por el profesor, pero buscando que el alumno experimente, busque información de forma autónoma para resolver los problemas que le vayan surgiendo e interprete los resultados obtenidos de acuerdo a los conocimientos adquiridos en la parte teórica de la asignatura.

2. TEMPORIZACIÓN

Las sesiones prácticas se llevarán a cabo en el **Aula SIM 3247 (INDUVa, Sede Doctor Mergelina de la Escuela de Ingenierías Industriales)**:

- Grupo **L1**
  - Sesión 1 (2 horas): **viernes 6** de septiembre de **09:00 a 11:00**
  - Sesión 2 (2 horas): **viernes 13** de septiembre de **09:00 a 11:00**
- Grupo **L2**
  - Sesión 1 (2 horas): **viernes 6** de septiembre de **11:00 a 13:00**
  - Sesión 2 (2 horas): **viernes 13** de septiembre de **11:00 a 13:00**

La distribución (orientativa) de las 4 horas de duración de la práctica será la siguiente:

<u>Primera sesión de la práctica (2 horas)</u>

1. Presentación (10’)
2. Inspección de la base de datos. Familiarización con el trabajo con datos clínicos (40’)
3. Descanso (10’)
4. Valores perdidos (*missing data*). Implementación de métodos de imputación (40’)
5. Consideraciones finales (10’)

<u>Segunda sesión de la práctica (2 horas)</u>

1. Presentación (10’)
2. Inspección de la base de datos. Familiarización con el trabajo con datos clínicos (40’)
3. Descanso (10’)
4. Valores atípicos (*outliers*). Implementación de métodos de detección de *outliers* (40’)
5. Consideraciones finales (10’)

*** La evaluación de esta práctica (Práctica 1) se realizará conjuntamente con los contenidos de la Práctica 2, una vez finalizadas todas las sesiones de ambas prácticas. Consistirá en un cuestionario tipo test que se realizará al principio de la primera clase de teoría de la asignatura que se realice tras terminar las sesiones de laboratorio (típicamente la semana siguiente).**

3. DESCRIPCIÓN GENERAL DEL PROBLEMA BAJO ESTUDIO

En esta práctica se sentarán las bases para construir un **modelo predictivo de ayuda al diagnóstico de una patología respiratoria**, es decir, identificar a aquellos pacientes con mayor probabilidad de padecer la enfermedad. Para ello, disponemos de una base de datos de **pacientes adultos con apnea obstructiva del sueño (AOS)**. La AOS es una enfermedad respiratoria relacionada con el sueño, en la que el paciente sufre eventos de ausencia total o parcial de flujo aéreo mientras duerme a causa del colapso de la vía aérea superior. El diagnóstico de la AOS se basa en la información obtenida de la polisomnografía nocturna hospitalaria, una prueba compleja, intrusiva, cara y con gran lista de espera. Por ello, desde hace años se demandan alternativas diagnósticas más sencillas que puedan simplificar el procedimiento diagnóstico de la enfermedad. El diseño de métodos automáticos de *machine learning* es uno de los enfoques empleados, con el objetivo de aprovechar al máximo la información obtenida mediante pruebas más sencillas (menos información, pero maximizando su potencial diagnóstico).

Disponemos de una base de datos real, que presenta los problemas típicos en el contexto de los repositorios de datos clínicos: faltan datos y han podido producirse errores en la transcripción de los mismos, pudiendo ambos afectar al entrenamiento y eficacia de los modelos predictivos que pretendemos implementar en las prácticas siguientes.

4. INSPECCIÓN DE LA BASE DE DATOS. CONSISTENCIA DE LOS DATOS: *MISSING VALUES* Y *OUTLIERS*

El primer paso antes de comenzar a diseñar un modelo predictivo multivariante es inspeccionar los datos que utilizaremos durante el proceso de diseño, para buscar inconsistencias, valores perdidos o errores de codificación, que podrían afectar enormemente al aprendizaje del modelo y a su rendimiento predictivo. En esta práctica, el alumno trabajará con la matriz de datos “BBDD_P1TCB”, que se encuentra disponible en el Campus Virtual de la asignatura, tanto en formato .XLSX (Excel) como en formato .MAT (Matlab).

A continuación, se proporciona un paquete de funciones de Matlab® que pueden resultar de utilidad durante la programación de las funcionalidades solicitadas en esta primera práctica:

```
find      boxplot  mean  isnan    robustcov      length

median   quantile  corr  robustfit  sum      abs   gscatter

knnsearch      sortrows      trimmean       zscore
```

El alumno será el responsable de investigar cuál es la funcionalidad de cada una de ellas a través de la ayuda de Matlab® y las utilizará cuando crea conveniente.

4.1. SESIÓN 1. Inspección de la base de datos. Valores perdidos (missing values)

La mayoría de las bases de datos en la práctica real presentan datos perdidos (*missing values*), es decir, valores que faltan en alguna de las variables de entrada para alguna de las observaciones/instancias. Los motivos pueden ser diversos: el valor es desconocido, no se ha

registrado (habitual en contextos clínicos) o que, simplemente, es irrelevante. La forma más común de indicar que un dato es un valor perdido es emplear valores fuera del rango normal de los datos, *e.g.*, un valor negativo cuando los datos solo pueden tomar valores positivos o un valor nulo cuando los datos por naturaleza son mayores que cero. También se puede dejar el campo vacío, cosa que Matlab® codifica empleando el valor *NaN*: *not a number*.

La mayoría de los métodos de *machine learning* necesitan conjuntos de datos completos, es decir, no pueden trabajar/tratar con datos perdidos. Ante esta situación, disponemos de dos opciones: (i) Selección de casos completos, que consiste en eliminar/excluir la instancia completa si alguna de sus variables presenta algún valor perdido, lo que disminuye la completitud o representatividad de la muestra y la generalización de los resultados; (ii) Selección por variables, que consiste en mantener todas las instancias/observaciones que sea posible eliminando las variables en las que se concentran más datos perdidos (es común que los datos perdidos no se distribuyan aleatoriamente, sino que estén asociados a determinadas variables); o (iii) Imputación de valores, que consiste en sustituir el dato perdido por un valor calculado "artificialmente" mediante algún procedimiento estadístico, empleando los valores válidos de otras variables y/o instancias de la base de datos.

En este primer apartado de la práctica, en primer lugar, utilice la función más apropiada de Matlab® para identificar/indexar los valores perdidos presentes en la base de datos. Una vez identificados, implementará en Matlab® algunas técnicas básicas de imputación de datos:

- **Imputación de la media global**. Consiste en sustituir todos los valores perdidos de la variable por la media global.
- **Imputación de la media de la clase**. Cuando se conoce la pertenencia a un determinado grupo/clase de cada una de las instancias/observaciones (pacientes), es posible calcular la media de la variable para cada clase y sustituir el valor perdido por el valor de la medida correspondiente a la clase de la instancia. Para ello, debéis buscar entre las variables de la base de datos si hay alguna que tenga aspecto de variable de agrupación.
- **Imputación de la media recortada** (global: OBLIGATORIO; o de la clase: OPTATIVO). Consiste en descartar un porcentaje de los datos antes de calcular la media para minimizar el efecto de posibles valores atípicos. En esta práctica, para cada variable que contenga valores perdidos, se descartará el 20% de su muestra: el 10% de los valores extremos inferiores y el 10% de los valores extremos superiores.
- **Imputación mediante los *k* vecinos más cercanos**. Consiste en buscar los *k* vecinos más cercanos para cada instancia con valores perdidos en una variable. La búsqueda de los *k* vecinos se hace sobre el resto de variables (que podrán tener valores perdidos o no) y omitiendo la propia instancia bajo análisis (o teniendo en cuenta que ella misma siempre será su propio vecino más cercano). El valor imputado será el de la media para la variable bajo estudio considerando solamente los *k* vecinos encontrados. En esta práctica se fijará un valor de *k* igual a 5.

Una vez implementado cada algoritmo, cree una nueva matriz de datos para cada uno de los métodos y compare los valores imputados con cada uno de ellos.

- ¿Se imputan los mismos valores con todos los métodos? ¿Qué ventajas e inconvenientes cree que tiene cada uno de ellos?

4.2. SESIÓN 2. Inspección de la base de datos. Datos atípicos (outliers)

Los *outliers* son observaciones con características muy diferentes a las demás, *i.e.*, no son representativos de la población bajo estudio y, por tanto, pueden afectar a los resultados (predicciones). Es importante diferenciar entre 2 tipos de *outliers* según su naturaleza: (i) pueden ser debidos a errores de transcripción/codificación (más comunes de lo que podría parecer), con lo que deberían detectarse y sustituirse mediante imputación de datos; o (ii) pueden ser valores correctos pero que, por la variabilidad natural del problema, se diferencian del resto de su clase, lo que podría ser un síntoma de falta de representatividad en la muestra de datos. En este último caso, lo mejor sería eliminarlo o mantenerlo, pero no cambiarlo mediante imputación (es habitual replicar los análisis con y sin los *outliers* para ver su influencia).

De forma general, los métodos de detección de *outliers* se pueden clasificar en:

- **Univariantes**. Analizan cada variable de forma independiente, sin tener en cuenta la influencia del resto de variables.
    - Los diagramas de cajas representan gráficamente algunos estadísticos básicos de la distribución de datos y, de paso, permiten detectar visualmente valores atípicos. Los *outliers* se representan como aquellos valores que se diferencian de la media más de entre 2 (para tamaños muestrales pequeños: <80 observaciones) y 3 veces (para tamaños muestrales más grandes: >80 observaciones) la desviación estándar.
      Utilizando la función adecuada de Matlab®, represente un diagrama de cajas para cada variable, de forma que puedan identificarse los valores anómalos. Si la representación se realiza en un mismo gráfico, es recomendable estandarizar las variables para suprimir las diferencias en la magnitud y rango de los datos de las diferentes variables y favorecer su visualización.
        - ¿Qué función permite dibujar diagramas de cajas en Matlab®?
        - ¿Qué estadísticos básicos se muestran?
        - ¿Cómo determina esta función los límites a partir de los cuales un valor se considera *outlier*?
- **Multivariantes**. Realizan la búsqueda de valores atípicos teniendo en cuenta todas las variables simultáneamente.
    - Los métodos más empleados se basan en la medida de distancias con respecto al denominado "centro de los datos", siendo la **distancia robusta de Mahalanobis** una de las más empleadas.

      Utilizando la función adecuada de Matlab®, identifique los valores *outliers* mediante la estimación robusta de la distancia de Mahalanobis. Mediante esta función, es posible modular (solo para alguno de los métodos de estimación que se pueden especificar como parámetro de entrada a la función) la sensibilidad con la que los datos serán considerados *outliers*. Utilice una fracción de *outliers* de 0.05 y mantenga el resto de opciones por defecto.
        - ¿Qué función permite tanto el cálculo de la distancia robusta de Mahalanobis como la detección de *outliers* mediante este método?
        - (**OPTATIVO**) ¿Qué umbral emplea esta función para decidir qué valores son *outliers*?
        - Visualice las observaciones de la base de datos en dos representaciones en dos dimensiones con diferentes parejas de variables (*e.g.*, variable 3 *vs.* variable 4; variable 2 *vs.* variable 5), identificando las instancias que son *outliers* y las que no. Interprete la distribución de los *outliers*.

5. EVALUACIÓN

La evaluación de las prácticas 1 y 2 se realizará conjuntamente el miércoles día **2 de octubre de 2024** al principio de la clase de teoría. Consistirá en un **cuestionario tipo test** sobre diversos aspectos vistos en los ejercicios propuestos en ambas prácticas y tendrá una **duración de 15 minutos**.