UNIVERSIDAD DE VALLADOLID

GRADO EN INGENIERÍA BIOMÉDICA

TÉCNICAS COMPUTACIONALES EN BIOMEDICINA

Práctica 2. Modelado de datos multidimensionales y rendimiento predictivo

CURSO 2024/2025

ÍNDICE

1. Objetivos y metodología 2

2. Temporización 2

3. Descripción general del problema bajo estudio 4

4. Métricas de rendimiento predictivo 4

4.1. SESIÓN 1. Regresión logística binaria 5

4.2. SESIÓN 2. Métricas de rendimiento predictivo 7

5. Evaluación 9

6. Bibliografía 9

1. OBJETIVOS Y METODOLOGÍA

En esta segunda práctica se va a implementar una nueva etapa dentro del procesado de datos multidimensionales. Tras el análisis descriptivo de la población de estudio y la búsqueda y tratamiento de inconsistencias y datos perdidos realizados en la Práctica 1, la base de datos ya está lista para la aplicación de técnicas de aprendizaje computacional encaminadas a la búsqueda de los patrones característicos de los pacientes bajo estudio. En esta práctica (i) se utilizarán los datos "limpios" resultantes de la práctica anterior para resolver un problema de ayuda al diagnóstico en el contexto de las enfermedades respiratorias y (ii) se evaluará el rendimiento predictivo del modelo diseñado mediante las métricas tradicionales derivadas de la matriz de confusión de 2 clases. Las variables clínicas de la base de datos que caracterizan a cada paciente se emplearán como variables independientes de entrada a un modelo predictivo que habrá que diseñar y evaluar. Los objetivos de la práctica consistirán en:

(i) Familiarizarse con el trabajo con datos clínicos reales.

(ii) Comprender el funcionamiento de uno de los algoritmos de análisis multivariante más empleados en el contexto clínico: la regresión logística binaria.

(iii) Saber calcular e interpretar las principales métricas de rendimiento para la evaluación de modelos predictivos.

Cada alumno realizará la práctica individualmente. Se propone un desarrollo guiado y supervisado por el profesor, pero buscando que el alumno experimente, busque información de forma autónoma para resolver los problemas que le vayan surgiendo e interprete los resultados obtenidos de acuerdo a los conocimientos adquiridos en la parte teórica de la asignatura.

2. TEMPORIZACIÓN

Las sesiones prácticas se llevarán a cabo en el aula **SIM-3247 del INDUVa, Sede Doctor Mergelina de la Escuela de Ingenierías Industriales**:

- Turno **L1**
  - Sesión 1 (2 horas): **viernes 20** de septiembre de **10:00 a 12:00** en **SIM-3247**
  - Sesión 2 (2 horas): **viernes 27** de septiembre de **10:00 a 12:00** en **SIM-3247**
- Turno **L2**
  - Sesión 1 (2 horas): **viernes 20** de septiembre de **12:00 a 14:00** en **SIM-3247**
  - Sesión 2 (2 horas): **viernes 27** de septiembre de **12:00 a 14:00** en **SIM-3247**

La distribución (orientativa) de las 4 horas de duración de la práctica será la siguiente:

Primera sesión de la práctica (2 horas)

1. Presentación (10')
2. Diseño e implementación de un clasificador binario mediante regresión logística (40')
3. Descanso (10')
4. Análisis y representación de la probabilidad de pertenencia a cada clase (predicción) (40')
5. Consideraciones finales (10')

Segunda sesión de la práctica (2 horas)

1. Presentación (10')
2. Implementación de métricas derivadas de la matriz de confusión (40')
3. Descanso (10')
4. Implementación del índice de Youden (OPTATIVO)
5. Consideraciones finales (10')

*** La evaluación de esta práctica (Práctica 2) se realizará conjuntamente con los contenidos de la Práctica 1, una vez finalizadas todas las sesiones de ambas prácticas. Consistirá en un cuestionario tipo test que se realizará al principio de la primera clase de teoría de la asignatura que se realice tras terminar las sesiones de laboratorio (típicamente la semana siguiente).**

3. DESCRIPCIÓN GENERAL DEL PROBLEMA BAJO ESTUDIO

En esta práctica vamos a construir un **modelo predictivo de ayuda al diagnóstico de una patología respiratoria**, es decir, identificar a aquellos pacientes con mayor probabilidad de padecer la enfermedad. Para ello, disponemos de una base de datos de **pacientes adultos con apnea obstructiva del sueño (AOS)**. La AOS es una enfermedad respiratoria relacionada con el sueño, en la que el paciente sufre eventos de ausencia total o parcial de flujo aéreo mientras duerme a causa del colapso de la vía aérea superior. El diagnóstico de la AOS se basa en la información obtenida de la polisomnografía nocturna hospitalaria, una prueba compleja, intrusiva, cara y con gran lista de espera. Por ello, desde hace años se demandan alternativas diagnósticas más sencillas que puedan simplificar el procedimiento diagnóstico de la enfermedad. El diseño de métodos automáticos de *machine learning* es uno de los enfoques empleados, con el objetivo de aprovechar al máximo la información obtenida mediante pruebas más sencillas (menos información, pero maximizando su potencial diagnóstico).

Los pacientes de nuestra base de datos están caracterizados mediante el registro de una única señal biomédica, que ha sido analizada de forma automática mediante diferentes métodos de procesado, dando lugar a un total de seis variables clínicas. Además, conocemos qué pacientes padecen (patológicos o AOS positivo) y no padecen (no patológicos o AOS negativo) la enfermedad en base a la polisomnografía de diagnóstico estándar. Utilizaremos esta información para crear un modelo predictivo de ayuda al diagnóstico mediante un enfoque de entrenamiento supervisado (*i.e.*, basado en ejemplos conocidos). **Como clasificador utilizaremos un modelo de regresión logística** (LR), un enfoque clásico muy empleado en biomedicina.

En esta práctica se empleará la misma base de datos que en la Práctica 1. Sin embargo, **se deberá utiliza una matriz de datos sin datos perdidos (*missing values*)**, resultante de la aplicación de cualquiera de los métodos de imputación de datos implementados en la práctica anterior. No es necesario eliminar los datos atípicos (*outliers*) detectados.

4. MÉTRICAS DE RENDIMIENTO PREDICTIVO

Una vez que se ha realizado el pre-procesado y análisis descriptivo de las variables en la base de datos, vamos a utilizar esta información para diseñar un modelo predictivo sencillo que nos permita trabajar con las **métricas básicas de rendimiento diagnóstico**. Para ello, utilizaremos la **regresión logística binaria (*logistic regression*, LR)**.

A continuación, se proporciona un paquete de funciones de Matlab® que pueden resultar de utilidad durante la programación de las funcionalidades solicitadas en esta segunda práctica de la asignatura:

```
size     glmfit    ones  length   exp  corr zeros     sum

plot      hold     axis sort  eps  glmval    zscore   max
```

El alumno será el responsable de investigar cuál es la funcionalidad de cada una de ellas a través de la ayuda de Matlab® y las utilizará cuando crea conveniente.

4.1. SESIÓN 1. Regresión logística binaria

LR es un algoritmo de **clasificación binaria** relativamente sencillo, pero uno de los más empleados en aplicaciones médicas cuando se trata de diferenciar dos clases de pacientes (sano *vs.* enfermo; fallece *vs.* no fallece; ingresa *vs.* no ingresa, etc.). Los algoritmos más sencillos en muchas ocasiones alcanzan rendimientos predictivos sorprendentemente altos en aplicaciones de la vida real. Por eso, siempre es buena idea probar con estos métodos, que, como mínimo, servirán de referencia para valorar la mejora en la precisión de otros métodos más complejos. De hecho, en el contexto del diseño de modelos predictivos clínicos, otros enfoques de *machine learning* más complejos no han demostrado obtener un rendimiento predictivo significativamente superior a la regresión logística (Christodoulou *et al*. 2019). En este mismo sentido, hay muchos problemas de clasificación que son, o se acercan mucho a ser, linealmente separables, lo que favorece el elevado rendimiento de los clasificadores lineales.

LR realiza una combinación lineal de las variables independientes (también conocidas como predictores o covariables) a la que aplica una **transformación** denominada ***logit***, cuyo objetivo es mapear el rango de valores de salida del modelo (*i.e.*, las predicciones) al intervalo [0, 1], lo que **permite interpretar la salida en términos de probabilidad** (Stoltzfus 2011):

- Partimos de la combinación lineal de las *p* variables independientes o predictoras:

$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p \qquad \text{(Eq. 1)}$$

- Que se puede expresar en forma de producto entre dos vectores fila de dimensión $1 \times (p+1)$ (*i.e.*, una fila y *p*+1 columnas):

$$\hat{Y} = \beta_0 + \sum_{i=1}^{p} \beta_i X_i = \beta_0 + X\beta^T = \mathbf{MB}^{\mathrm{T}} \qquad \text{(Eq. 2)}$$

  donde **M** es el vector fila de predictores (variables independientes) al que se ha añadido un 1 en la primera posición para poder incorporar el término constante o independiente (también llamado interceptor) al modelo, mientras que **B** es el vector fila de coeficientes del modelo $[\beta_0\ \beta_1\ \beta_2\ \ldots\ \beta_p]$.
- La transformación *logit* modifica la combinación lineal de variables inicial de la forma:

$$Ln\left(\frac{\hat{Y}}{1-\hat{Y}}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p \qquad \text{(Eq. 3)}$$

  con lo que la **probabilidad de pertenencia a la clase positiva** (*i.e.*, que se produzca el evento: padecer la enfermedad bajo estudio, fallecer, visitar urgencias, ingresar en el hospital, etc.), que se suele codificar como Y=1, se calcula como:

$$Probabilidad\ del\ evento\ (\hat{Y} = 1) = \frac{e^{\mathbf{MB}^T}}{1+e^{\mathbf{MB}^T}} = \frac{e^{\beta_0+\beta_1 X_1+\beta_2 X_2+\cdots+\beta_p X_p}}{1+e^{\beta_0+\beta_1 X_1+\beta_2 X_2+\cdots+\beta_p X_p}} \qquad \text{(Eq. 4)}$$

La forma en que LR se emplea para implementar un **clasificador binario** es la siguiente:

- Primero, se emplea un conjunto de datos de entrenamiento (una matriz con los valores de las variables independientes para un conjunto de observaciones/pacientes) para calcular los coeficientes $[\beta_0\ \beta_1\ \beta_2\ \ldots\ \beta_p]$, que son los que definen la ecuación del modelo predictivo.
- Cuando el modelo se aplica a una nueva observación/instancia (*i.e.*, a un nuevo vector con los valores de las variables independientes o predictoras), obtenemos a la salida la probabilidad de pertenencia a la clase Y=1 para esa observación/instancia/paciente.
- Para convertir el valor de probabilidad en una predicción concreta de la clase Y = 0 o Y = 1 basta con implementar un proceso de umbralización, es decir, fijar un umbral de probabilidad de tal forma que:

Probabilidad ≥ umbral → clase estimada $\hat{Y} = 1$
Probabilidad < umbral → clase estimada $\hat{Y} = 0$

La variación de este umbral influirá en las métricas de rendimiento predictivo del clasificador. Hay diferentes enfoques para determinar el umbral óptimo, dependiendo de los datos y de la naturaleza del problema bajo estudio. El valor natural por defecto es 0.5, es decir, una probabilidad del 50%. Siempre se puede utilizar, pero lo adecuado es utilizarlo cuando ambas clases son equiprobables, es decir, que las probabilidades *a priori* de cada clase son iguales.

En esta parte de la práctica, el alumno utilizará la información proporcionada sobre el funcionamiento de la regresión logística para implementar un clasificador binario, que evaluará mediante las métricas de rendimiento predictivo vistas en las clases de teoría.

CONSIDERACIONES PREVIAS IMPORTANTES

- Considere **toda la base de datos como un único conjunto de entrenamiento** y construya un modelo LR, es decir, obtenga los coeficientes de la ecuación de regresión logística. Para ello, deberá **identificar** en la base de datos qué variable es la **variable dependiente** (***targets***) y cuáles son las **variables independientes** (**predictores**).
- Utilice la matriz de datos con los **datos perdidos imputados mediante alguno de los métodos de imputación** implementados en la Práctica 1 (preferiblemente el basado en kNN) y **sin eliminar ningún *outlier***.
- Es necesario **estandarizar las variables** que componen la matriz de datos, es decir, transformar cada variable para que tenga **media nula y varianza unidad**. De esta forma se evitan grandes diferencias en las magnitudes y rangos de las variables que dificultan la estimación de los coeficientes del modelo.
- Es necesario **evitar la colinealidad y la multi-colinealidad** entre las diferentes variables que componen la matriz de datos, es decir, **detectar y evitar variables que tengan una alta correlación** entre sí o que puedan obtenerse como combinación lineal de otras variables. Esto hace que el modelo sea inestable y no generalizable. Coeficientes con valores muy elevados son un indicio de colinealidad.

PASOS A SEGUIR

- Utilice la ayuda de Matlab® para buscar la función más adecuada para implementar modelos LR (transformación *logit*) y analice su funcionamiento. Construya el modelo LR para la matriz de datos y el vector de *targets* con los que está trabajando.
    - ¿Qué ocurre cuando se utilizan todas las variables independientes para construir el modelo predictivo? ¿Cómo son los coeficientes del modelo?
- Inspeccione la matriz de correlaciones de las variables independientes y elimine del modelo aquella(as) variable(es) que muestre(en) mayor correlación con el resto (al menos aquellas con r >0.8). Implemente un nuevo modelo LR con las variables restantes.
    - En el vector de coeficientes del nuevo modelo, ¿qué índice se corresponde con el término independiente? ¿Es posible eliminar este término constante del modelo?
- Una vez que tenga los coeficientes, aplique el modelo obtenido sobre los mismos datos de entrenamiento. Recuerde que esto no nos va a aportar ninguna información sobre el rendimiento predictivo real del clasificador, pero nos ayudará a visualizar la influencia

del umbral de probabilidad empleado para clasificar. Para ello, en primer lugar, busque en la ayuda de Matlab® la función de evaluación de modelos LR, aplíquela sobre todas las instancias/observaciones de la base de datos y visualice las predicciones, es decir, las probabilidades de pertenencia a la clase Y = 1 para cada paciente.

- Ahora, trate de reproducir estos mismos resultados implementando y aplicando directamente la ecuación de cálculo de la probabilidad de pertenencia a la clase (Eq. 4), sin emplear la función de Matlab®.
    - ¿Ha conseguido alcanzar los mismos resultados? ¿Qué ha tenido que hacer para aplicar el término independiente del modelo?
- A continuación, aplique un umbral de probabilidad del 50% para convertir la probabilidad de pertenencia a la clase Y=1 en la predicción final de la clase a la que pertenece cada observación/instancia (*i.e.*, cada paciente). Visualice las predicciones acertadas (verdaderos positivos y verdaderos negativos) y las erróneas (falsos positivos y falsos negativos) de la siguiente forma (ver PowerPoint de la Práctica 1):
    i. En el eje *y* de ordenadas se representará la probabilidad de pertenencia a la clase (la estimación realizada), mientras que en el eje *x* de abscisas se representará la clase real (Y =0 *vs.* Y=1).
    ii. Todas las instancias de la clase negativa (Y=0) agrupadas, donde cada instancia estará representada por un cuadrado con borde azul. Si la instancia está correctamente clasificada (verdadero negativo) el cuadrado estará vacío, mientras que si fue clasificada erróneamente (falso positivo) se representará mediante un cuadrado relleno de color rojo.
    iii. Todas las instancias de la clase positiva (Y=1) agrupadas, donde cada instancia estará representada por un triángulo con borde azul. Si la instancia está correctamente clasificada (verdadero positivo) el triángulo estará vacío, mientras que si fue clasificada erróneamente (falso negativo) se representará mediante un triángulo relleno de color rojo.
    iv. Finalmente, represente mediante una línea discontinua horizontal el umbral de probabilidad aplicado para clasificar.
- Seguidamente, utilice un umbral de probabilidad más pequeño (*e.g.*, del 25%) para implementar la clasificación y visualice el resultado en una nueva figura siguiendo la misma nomenclatura que para la figura anterior. De la misma forma, repita la clasificación y la figura para un umbral de probabilidad mayor (*e.g.*, del 75%).
    - ¿Qué ha ocurrido al disminuir o al aumentar el umbral de probabilidad? ¿Cómo se puede utilizar esta propiedad para adaptar/cambiar el comportamiento del modelo predictivo en función de la naturaleza del problema bajo estudio (*e.g.*, en función del coste de error de clasificación)?

4.2. SESIÓN 2. Métricas de rendimiento predictivo

4.2.1. Métricas de rendimiento derivadas de la matriz de confusión

Para finalizar esta práctica:

- **Para cada uno de los umbrales** de probabilidad con los que ha trabajado (25%, 50% y 75%), **calcule su matriz de confusión** y las **métricas de rendimiento** predictivo tradicionales para la salida del modelo de regresión logística implementado en la primera parte de la práctica: sensibilidad (Se), especificidad (Sp), valor predictivo

positivo (PPV), valor predictivo negativo (NPV), razón de verosimilitud positiva (LR+), razón de verosimilitud negativa (LR-) y precisión (Acc). Recuerde aplicar el modelo LR a la matriz de datos con los datos perdidos imputados y sin eliminar los *outliers*. Rellene las siguientes tablas:

		ESTIMACIÓN DEL MODELO LR	
		No patológico (Y = 0)	**Patológico (Y = 1)**
CLASE REAL	**No patológico (Y = 0)**	**TN**	FP
	Patológico (Y = 1)	FN	**TP**

Matriz de confusión: TP (*true positives* o verdaderos positivos); TN (*true negatives* o verdaderos negativos); FP (*false positives* o falsos positivos); FN (*false negatives* o falsos negativos).

Umbral de probabilidad	Se (%)	Sp (%)	PPV (%)	NPV (%)	LR+	LR-	Acc (%)
50%							
25% (Optativo)							
75% (Optativo)							

Se: sensibilidad; Sp: especificidad; PPV: valor predictivo positivo; NPV: valor predictivo negativo; LR+: razón de verosimilitud positiva; LR-: razón de verosimilitud negativa; Acc: precisión.

4.2.2. Índice de Youden (OPTATIVO)

Como se ha observado en el ejercicio anterior, el valor del umbral empleado para transformar la probabilidad de pertenencia a la clase en una predicción concreta de una de las clases bajo estudio influye enormemente en el número de instancias correcta e incorrectamente clasificadas y, por consiguiente, en las métricas de rendimiento predictivo. Cuando las clases no son equiprobables, por ejemplo, cuando hay una clase mayoritaria en el conjunto de entrenamiento, este umbral se suele optimizar con la ayuda de la curva ROC, que recordemos era la representación de la tasa de falsos positivos (eje x) frente a la tasa de verdaderos positivos (eje y) para diferentes umbrales del espacio de trabajo (en nuestro caso, distintas probabilidades de pertenencia a la clase). Un índice derivado de la curva ROC muy empleado en medicina para determinar el umbral de mayor efectividad de biomarcadores diagnósticos es el índice de Youden (*J*), que se define formalmente como (Ruopp *et al*. 2008):

$$J = \max_{umbral} \{Se(umbral) + Sp(umbral) - 1\}$$

donde (Se, Sp) es el par sensibilidad-especificidad para cada valor fijo del umbral. El umbral que maximice esta expresión será considerado como el umbral de diagnóstico óptimo. Bajo este enfoque, se asume el mismo peso para la sensibilidad que para la especificidad, es decir, ambas son igual de importantes o, lo que es lo mismo, el coste del error en la clasificación de un sujeto no patológico o "sano" (falso positivo) y el coste del error en la clasificación de un sujeto patológico (falso negativo) es el mismo.

- Implemente el cálculo del índice de Youden y aplíquelo a la salida del modelo LR implementado en la sección previa.
    - ¿Es muy diferente el umbral óptimo correspondiente al índice *J* con respecto al umbral de probabilidad natural por defecto del 50%? ¿A qué puede ser debido?
    - Calcule las métricas de rendimiento tradicionales (Se, Sp, PPV, NPV, LR+, LR- y Acc) para el índice de Youden y compárelas con las obtenidas para los umbrales calculados anteriormente.

5. EVALUACIÓN

La evaluación de las prácticas 1 y 2 se realizará conjuntamente el día **2 de octubre de 2024** al principio de la clase de teoría. Consistirá en un **cuestionario tipo test** sobre diversos aspectos vistos en los ejercicios propuestos en ambas prácticas y tendrá una **duración de 15 minutos**.

6. BIBLIOGRAFÍA

Christodoulou E, Ma J, Collins GS, Steyerberg EW, Verbakel JY, Van Calster B. A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. Journal of Clinical Epidemiology 2019; 110:12–22.

Ruopp MD, Perkins NJ, Whitcomb BW, Schisterman EF. Youden index and optimal cut-point estimated from observations affected by a lower limit of detection. Biom J. 2008; 50(3): 419–430.

Stoltzfus JC. Logistic Regression: A Brief Primer. Academic Emergency Medicine 2011; 18:1099–1104.