UNIVERSIDAD DE VALLADOLID

GRADO EN INGENIERÍA BIOMÉDICA

TÉCNICAS COMPUTACIONALES EN BIOMEDICINA

Práctica 3. *Bootstrapping*

CURSO 2024/2025

ÍNDICE

1. Objetivos y metodología 2

2. Temporización 2

3. Descripción general del problema bajo estudio 3

4. *Bootstrapping* 3

4.1. Bootstrap 0.632 4

4.2. Cálculo de intervalos de confianza (OPTATIVO) 5

5. Evaluación 5

1. OBJETIVOS Y METODOLOGÍA

En esta tercera práctica se va a abordar el empleo de las técnicas de *bootstrap* para estimar métricas de rendimiento predictivo de modelos de aprendizaje computacional. Para ello: (i) se utilizarán los datos "limpios" resultantes de la primera práctica y (ii) se evaluará de forma exhaustiva el rendimiento predictivo de un modelo automático como el implementado en la práctica 2 (clasificador binario). Los objetivos de la práctica consistirán en:

(i) Familiarizarse con el trabajo con datos clínicos reales.

(ii) Conocer y comprender el uso de las técnicas de *bootstrapping* en la estimación robusta de métricas de rendimiento predictivo y de sus intervalos de confianza.

Cada alumno realizará la práctica individualmente. Se propone un desarrollo guiado y supervisado por el profesor, pero buscando que el alumno experimente, busque información de forma autónoma para resolver los problemas que le vayan surgiendo e interprete los resultados obtenidos de acuerdo a los conocimientos adquiridos en la parte teórica de la asignatura.

2. TEMPORIZACIÓN

La única sesión de la que consta esta práctica se desarrollará en el **Aula SIM 3247 (Escuela de Ingenierías Industriales, Sede Doctor Mergelina)** el día **4 de octubre**, en las horas asignadas a las prácticas de laboratorio:

- Grupo **L1**: viernes de **09:00 a 11:00**.
- Grupo **L2**: viernes de **11:00 a 13:00**.

La distribución (orientativa) de las 2 horas de duración de la práctica será la siguiente:

Sesión práctica única (2 horas)

1. Presentación (10')
2. Diseño e implementación del método *bootstrap* 0.632 (40')
3. Descanso (10')
4. Cálculo de intervalos de confianza (40') (**OPTATIVO**)
5. Consideraciones finales (10')

*** La evaluación de esta práctica (Práctica 3) se realizará conjuntamente con los contenidos de la Práctica 4, una vez finalizadas todas las sesiones de ambas prácticas. Consistirá en un cuestionario tipo test que se realizará al principio de la primera clase de teoría de la asignatura que se realice tras terminar las sesiones de laboratorio (típicamente la semana siguiente).**

3. DESCRIPCIÓN GENERAL DEL PROBLEMA BAJO ESTUDIO

El contexto del estudio (temática del problema a resolver) es el mismo que en las prácticas anteriores: **ayuda al diagnóstico** de pacientes con sospecha de padecer **apnea obstructiva del sueño (AOS)**. La AOS es una enfermedad respiratoria relacionada con el sueño, en la que el paciente sufre eventos de ausencia total o parcial de flujo aéreo mientras duerme a causa del colapso de la vía aérea superior. El **diseño** de nuestro sistema automático de ayuda a la toma de decisiones clínicas se abordará mediante la **resolución de un problema de clasificación binaria** bajo un enfoque de **aprendizaje supervisado** (*i.e.*, basado en ejemplos conocidos). Disponemos de una población de estudio (base de datos o *dataset*) donde cada paciente está caracterizado por un total de seis variables clínicas derivadas del procesado automático de una señal biomédica. Además, conocemos qué pacientes padecen (patológicos o AOS positivo: clase positiva, que codificaremos mediante la etiqueta "1") y no padecen (no patológicos o AOS negativo: clase negativa, que codificaremos mediante la etiqueta "0") la enfermedad en base a la polisomnografía de diagnóstico estándar (*gold standard* o referencia). Como clasificador utilizaremos un modelo de **regresión logística (LR)**. La **validación** del modelo diseñado se realizará mediante las métricas tradicionales derivadas de una matriz de confusión de 2 clases. Como en la evaluación de cualquier modelo predictivo, es recomendable acompañar a las medidas de rendimiento de alguna **estimación del error** cometido que nos permita interpretar cómo de fiables son esas medidas. Dado que la base de datos no es muy extensa, emplear alguna **técnica de *bootstrap*** para obtener dichas medidas de error daría lugar a estimaciones más robustas.

4. *BOOTSTRAPPING*

Las técnicas de *bootstrapping* permiten estimar de forma robusta "cómo de precisa/buena" es a su vez la estimación de alguna propiedad de una muestra de datos. Esta propiedad puede ser tan sencilla como un valor medio (valor esperado; con expresión matemática conocida) o tan "compleja" como la sensibilidad de un modelo predictivo cuyo cálculo requiere la implementación de diferentes etapas que pueden llegar a tener un coste computacional elevado (sin expresión matemática cerrada). Como se ha informado en las clases teóricas del tema correspondiente a las técnicas de *bootstrap*, la forma de expresar cómo de buena es la estimación consiste en acompañar al valor estimado de diferentes estadísticos/medidas de error, como el error estándar o el intervalo de confianza.

Los algoritmos de *bootstrapping* son muy empleados en diferentes etapas del diseño de modelos de *machine learning*, especialmente cuando el tamaño del conjunto de entrenamiento no es muy grande. En esta práctica, el alumno implementará el método *bootstrap 0.632*, que está **especialmente pensado para estimar el error predictivo en problemas de clasificación**.

A continuación, se proporciona un conjunto de funciones de Matlab® que pueden resultar de utilidad durante la programación de las funcionalidades solicitadas en la práctica:

```
bootstrp  ismember  size  histogram   mean  std   isempty

glmfit  ones  glmval   mean  quantile  repmat
```

El alumno será el responsable de investigar cuál es la funcionalidad de cada una de ellas a través de la ayuda de Matlab® y las utilizará cuando crea conveniente.

4.1. Bootstrap 0.632

El enfoque de *bootstrap* para estimar el error en contextos de clasificadores automáticos se basa en que el error calculado únicamente sobre el conjunto de datos de entrenamiento es demasiado optimista, es decir, está sesgado, con lo que se propone estimar ese sesgo mediante muestreo con reemplazo (calculando el error para cada muestra de *bootstrap*, viendo para cada una de ellas la diferencia con respecto al error global y haciendo posteriormente la media), para restarlo finalmente al error optimista calculado inicialmente y obtener una nueva estimación, ya sin sesgo. La idea de *bootstrap* 0.632 es que la componente de error optimista se corresponde con el error asociado a las muestras de *bootstrap* (conjuntos de entrenamiento) y que la componente de sesgo se corresponde con las instancias que quedan fuera de cada muestra de *bootstrap* (conjuntos de test). En lugar de restar, *bootstrap* 0.632 propone una suma ponderada de ambas componentes de error:

$$e_{boot\ 0.632} = \frac{1}{B}\sum_{b=1}^{B}\left(0.368 \times e_{train(b)} + 0.632 \times e_{test(b)}\right) \qquad \text{(Eq. 1)}$$

donde *B* es el número de réplicas de *bootstrap*. **Un aspecto importante de esta técnica es que se puede extender al cálculo de cualquiera de las métricas de rendimiento predictivo de un clasificador**, no solamente al error.

En esta sesión práctica, el alumno implementará en Matlab® el método de *bootstrap* 0.632 para **estimar las siguientes métricas**: sensibilidad, especificidad, valor predictivo positivo, valor predictivo negativo, razón de verosimilitud positiva, razón de verosimilitud negativa y precisión.

- Como modelo predictivo, implemente una metodología basada en LR como la utilizada en la práctica 2, aplicándola a la matriz de datos con los datos perdidos imputados mediante algún método de imputación (preferiblemente KNN) construida en la práctica 1, sin eliminar ningún *outlier* y descartando la variable(s) redundante detectada(s).
- En cada iteración de *bootstrap* dispondrá de un conjunto de entrenamiento (instancias que están en la muestra de *bootstrap*), que empleará para diseñar un modelo LR (obtener sus coeficientes), y de un conjunto de test (instancias que no están en la muestra de *bootstrap*), que empleará para evaluar dicho modelo.
- Como umbral para clasificar utilice una probabilidad estándar del 50%.
- Utilice el número de iteraciones/muestras de *bootstrap* que considere adecuado para la estimación de estos estadísticos de rendimiento (recordad lo visto en la teoría).
- **IMPORTANTE**
    - Como en cualquier proceso de entrenamiento y test (*hold-out*), es necesario estandarizar los datos, tanto de entrenamiento como de test. Las variables de la matriz de entrenamiento se transformarán (media nula y desviación típica unidad) utilizando sus propias medias y desviaciones estándar. Esta misma transformación, utilizando las medias y las desviaciones estándar de las variables en el conjunto de entrenamiento, serán las que deban aplicarse a los datos de test. **Como en los procedimientos de *bootstrap* se generan múltiples matrices de entrenamiento y test, el proceso de estandarización deberá aplicarse para cada nuevo par de matrices de entrenamiento y test surgidas en cada iteración del algoritmo**.
    - En el proceso de clasificación basado en LR siempre es necesario fijar un umbral de probabilidad para convertir la "probabilidad de pertenencia" en la "clase estimada".

i. Si empleamos un umbral de probabilidad fijo, este será siempre el mismo y no variará durante las iteraciones, pero…
ii. … si se emplease el índice de Youden como umbral de probabilidad, **sería necesario re-calcular dicho umbral para cada nuevo modelo construido en cada iteración de *bootstrap***. Este umbral optimizado en cada réplica de entrenamiento sería el que se aplicase sobre cada subconjunto de test.

Complete la siguiente tabla con las estimaciones *bootstrap* de cada métrica de rendimiento obtenida aplicando la (Eq. 1):

	Se (%)	**Sp (%)**	**PPV (%)**	**NPV (%)**	**LR+**	**LR-**	**Acc (%)**
Métrica $_{boot\ 0.632}$							

Se: sensibilidad; Sp: especificidad; PPV: valor predictivo positivo; NPV: valor predictivo negativo; LR+: razón de verosimilitud positiva; LR-: razón de verosimilitud negativa; Acc: precisión.

4.2. Cálculo de intervalos de confianza (OPTATIVO)

Como se ha indicado, las técnicas de *bootstrap* también se emplean en la estimación robusta de intervalos de confianza. En esta última parte de la práctica se **empleará la distribución de valores de cada métrica derivados de las *B* iteraciones de *bootstrap*** para estimar el **intervalo de confianza del 95% (IC95%)** para cada uno de ellos mediante la **técnica de los percentiles de *bootstrap*** vista en el Tema 2 de la asignatura.

- Utilice el número de iteraciones/muestras de *bootstrap* que considere adecuado para la estimación de intervalos de confianza (recordad lo visto en la teoría).
- **Cumplimente la siguiente tabla** con los IC95% obtenidos para cada métrica:

	Se (%)	**Sp (%)**	**PPV (%)**	**NPV (%)**	**LR+**	**LR-**	**Acc (%)**
IC95%							

IC95%: intervalo de confianza del 95%; Se: sensibilidad; Sp: especificidad; PPV: valor predictivo positivo; NPV: valor predictivo negativo; LR+: razón de verosimilitud positiva; LR-: razón de verosimilitud negativa; Acc: precisión.

- **Dibuje un histograma** con la distribución de *bootstrap* de la métrica de precisión diagnóstica (Acc) y **marque los cuantiles** que definen el intervalo de confianza del 95%. Para dibujar el histograma, tenga en cuenta el rango de variación de la métrica y utilice un número suficiente de *bins* como para capturar la variabilidad de la distribución. **Represente los datos en forma de frecuencia normalizada (probabilidad)**.

5. EVALUACIÓN

La evaluación de las prácticas 3 y 4 se realizará conjuntamente el día **23 de octubre de 2024** al principio de la clase de teoría. Consistirá en un **cuestionario tipo test** sobre diversos aspectos vistos en los ejercicios propuestos en ambas prácticas y tendrá una **duración de 15 minutos**.